



RECONOCIMIENTO DE EMOCIONES & CREACIÓN DE EMOCIONES SINTÉTICAS & VISUALIZACIÓN



ALBERTO PADILLA & MARCO A. HERNANI

Assembler
Institute of Technology




ÍNDICE

1. **Objetivos y Motivación.**
2. **¿Qué tipos de datos son EEG y librería MNE?.**
3. **DataSets.**
4. **Incidencias DataSets.**
5. **Proceso ETL.**
 - Trial General.
 - Interpolación.
 - Bandas de Frecuencia + 4D.
6. **Modelo de Reconocimiento de emociones (CNN)**
 - Resultados.
 - Visualización.
7. **Modelo Generador de señales sintéticas (GAN)**
 - ¿Qué es GAN?
 - Resultados.
 - Visualización.
8. **Conclusiones.**
9. **Incidencias Modelos.**
10. **Trabajos Futuros**
11. **Agradecimientos.**


A stylized, glowing blue brain is shown inside a human head silhouette. The brain is rendered with a translucent, wireframe-like texture, giving it a futuristic or digital appearance. The word "COMENZAMOS" is overlaid in the center of the brain in a bold, red, serif font.

COMENZAMOS




1. Objetivo nº1: Reconocimiento de Emociones

ETL




# mean_0_a	mean_1_a	mean_2_a	mean_3_a	mean_4_a
4.62E+00	3.03E+01	-3.56E+02	1.56E+01	2.63E+01
2.88E+01	3.31E+01	3.20E+01	2.58E+01	2.28E+01
8.90E+00	2.94E+01	-4.16E+02	1.67E+01	2.37E+01
1.49E+01	3.16E+01	-1.43E+02	1.98E+01	2.43E+01
2.83E+01	3.13E+01	4.52E+01	2.73E+01	2.45E+01
3.10E+01	3.09E+01	2.96E+01	2.85E+01	2.40E+01
1.08E+01	2.10E+01	4.47E+01	4.87E+00	2.81E+01
1.78E+01	2.78E+01	-1.02E+02	1.69E+01	2.69E+01
1.15E+01	2.97E+01	3.49E+01	1.02E+01	2.69E+01
8.91E+00	2.92E+01	-3.14E+02	6.51E+00	3.09E+01
5.21E+00	2.84E+01	1.85E+01	3.66E+00	2.26E+01



% PRECISIÓN




CNN




1. Objet. y Motiv.

2. ¿EEG y MNE?
3. DataSets
4. Incidencias DataSets
5. ETL
6. CNN
7. GAN
- 8-11 ...




1. Objetivo nº2: Creación de Señales Sintéticas


ETL



#	mean_0_a	mean_1_a	mean_2_a	mean_3_a	mean_4_a
4.62E+00	3.03E+01	-3.56E+02	1.56E+01	2.63E+01	
2.88E+01	3.31E+01	3.20E+01	2.58E+01	2.28E+01	
8.90E+00	2.94E+01	-4.16E+02	1.67E+01	2.37E+01	
1.49E+01	3.16E+01	-1.43E+02	1.98E+01	2.43E+01	
2.83E+01	3.13E+01	4.52E+01	2.73E+01	2.45E+01	
3.10E+01	3.09E+01	2.96E+01	2.85E+01	2.40E+01	
1.08E+01	2.10E+01	4.47E+01	4.87E+00	2.81E+01	
1.78E+01	2.78E+01	-1.02E+02	1.69E+01	2.69E+01	
1.15E+01	2.97E+01	3.49E+01	1.02E+01	2.69E+01	
8.91E+00	2.92E+01	-3.14E+02	6.51E+00	3.09E+01	
5.21E+00	2.84E+01	1.85E+01	3.66E+00	2.26E+01	




VISUALIZACIÓN




SEÑAL
ARTIFICIAL




GAN








1. Motivación

- Transformar los pensamientos a formato digital.
- Conocer el estado de un paciente sin necesidad de hablar.
- Ayudar la comunicación con extremidades artificiales.
- Realidad Virtual en los videojuegos.
- Estímulos artificiales para enfermedades neurodegenerativas como el Alzheimer y la demencia.



2. ¿Qué tipos de datos son EEG?



1. Objet. y Motiv.

2. ¿EEG y MNE?

3. DataSets


4. Incidencias DataSets

5. ETL


6. CNN

7. GAN

8-11 ...



2. ¿Qué tipos de datos son EEG?



<RawCNT | 6_3_20180802.cnt, 66 x 3117520 (3117.5 s), ~68 kB, data no

<Info | 8 non-empty values

bads: []

ch_names: FP1, FP2, FP2, AF3, AF4, F7, F5, F3, F1, FZ, F2, F4, F6,
chs: 66 EEG

custom_ref_applied: False

highpass: 0.0 Hz

lowpass: 500.0 Hz


meas_date: 2018-02-08 03:46:51 UTC

nchan: 66

projs: []

sfreq: 1000.0 Hz

subject_info: 5 items (dict)



2. Librería MNE

ESTIMACIÓN

MODELOS DE
CODIFICACIÓN

CONECTIVIDAD


VISUALIZACIÓN

ESTADÍSTICA

MACHINE
LEARNING



- Paquete Python de código abierto para explorar, visualizar y analizar datos neurofisiológicos humanos: MEG, **EEG**, sEEG, ECoG, NIRS...




3. DataSets.

SEED: EEG de **15 sujetos**. Los datos se recogieron mientras veían fragmentos de películas. Los vídeos se seleccionaron cuidadosamente para inducir distintos tipos de emociones: positivas, negativas y neutras.

SEED_V: EEG de **20 sujetos**. Evolución del conjunto de datos original de SEED. El número de categorías de emociones cambia a cinco: feliz, triste, miedo, asco y neutro.

SEED_GER: EEG de **8 sujetos** alemanes con etiquetas emocionales positivas, negativas y neutras.


SEED_FRA: EEG de **8 sujetos** franceses con etiquetas emocionales positivas, negativas y neutras.



1. Objet. y Motiv.
2. ¿EEG y MNE?
3. DataSets
4. Incidencias DataSets
5. ETL
6. CNN
7. GAN
- 8-11 ...




Assembler
Institute of Technology



4. Incidencias DataSets


- Investigación de los experimentos realizados para conformar el datasets. Adaptación en algunos casos.
- Acceso a Datos. (Univ. Harvard **X** - Univ. Shangai **✓** - Otros **✓**)
- Compatibilidad de DataSets
- Tamaño de los archivos (sol: csv. ($\pm 30\text{GB}$) - .parquet ($\pm 3\text{Gb}$) - .fif ($\pm 3\text{Gb}$))
- Comparar matrices: $= \text{n}^\circ \text{ columnas} \neq \text{n}^\circ \text{ filas}$.

1.	Objet. y Motiv.
2.	¿EEG y MNE?
3.	DataSets
4.	Inc. DataSets
5.	ETL
6.	CNN
7.	GAN
8-11	...




5. Proceso de ETL:

○ Trial general







1. Objet. y Motiv.
2. ¿EEG y MNE?
3. DataSets
4. Incidencias DataSets
5. **ETL**
6. CNN
7. GAN
- 8-11 ...



5. Proceso de ETL:


- Trial General






5. Proceso de ETL:

- Interpolación





5. Proceso de ETL:

- Bandas de Frecuencia + 4D

**Frecuencia =
Velocidad Onda**

**Bandas = Estados
Mentales**



GAMMA:
Active Thought

5



BETA:
Alert, Working



ALPHA:
Relaxed, Reflective




THETA:
Drowsy, Meditative[



DELTA:
Sleepy, Dreaming

1




6. Modelo de Reconocimiento de Emociones (CNN)

○ Resultados

epochs = 20

batch_size = 32

learning rate=0.001



ACC. TEST: 0.3724

ACC. TRAIN: 0.3625

1-5

...

6.

CNN

7.

GAN

8.

Conclusiones

9.


Incidencias Modelos

10.

Trabajos Futuros



11.


Agradecimientos



6. Modelo de Reconocimiento de Emociones (CNN)

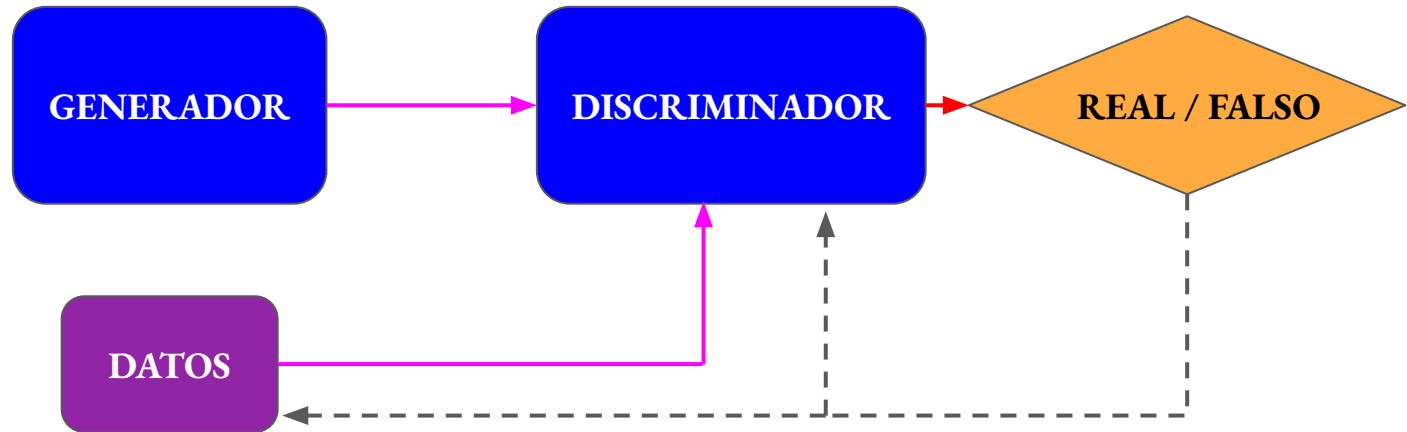
○ Visualización






7. Modelo Generador de Señales Sintéticas (GAN)

○ ¿Qué es?






7. Modelo Generador de Señales Sintéticas (GAN)


○ Resultados

epochs = 100
batch_size = 32
learning rate
discriminator=0.0002



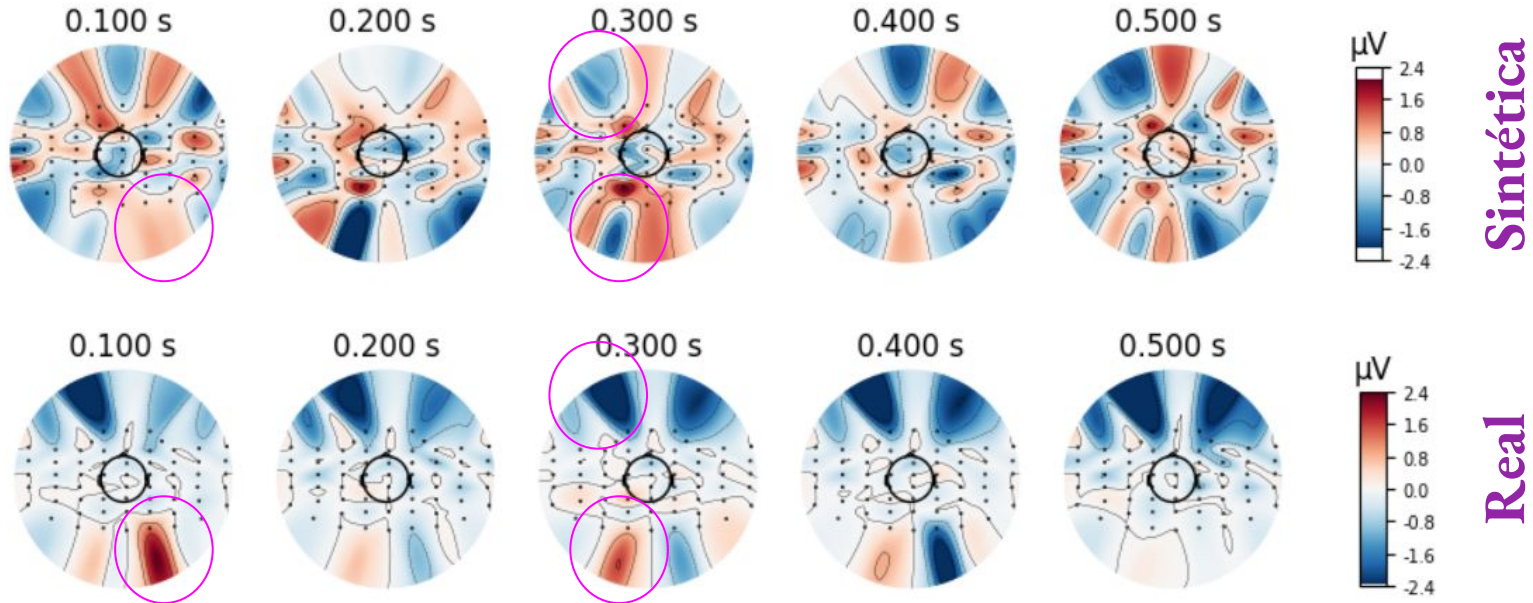
[D loss: 3.985933780670166, acc.: 34.375]


[G loss: 2.191690444946289]



7. Modelo Generador de Señales Sintéticas (GAN)


○ Visualización (Positivo)






7. Modelo Generador de Señales Sintéticas (GAN)


- Visualización (Positivo)



Sintética




Real



8. Conclusiones


- **Reconocimiento de Emociones (CNN):**
 - El modelo es muy sencillo.
 - Falta de un módulo de atención autoadaptativo formado por dos submódulos, el módulo de atención espacial y el módulo de atención espectral.
- **Creación de Señales Sintéticas (GAN):**
 - Discriminador tiene una alta precisión.
 - La pérdida del generador es alta y todavía se puede mejorar.
 - Gran Coste de Computación.
 - Señales reales y sintéticas muy distintas debido a la interpolación (50s).



9. Incidencias Modelos


- Gran cantidad de datos pero poco representativos.
- Alto coste computacional.
- Altos tiempos de ejecución. (7h para ventanas de 2s)
- Pérdida de datos. (interpolación)

1-5	...
6.	CNN
7.	GAN
8.	Conclusiones
9.	Incid. Modelos
10.	Trabajos Futuros
11.	Agradecimientos



10. Trabajos Futuros

- **1º Mejorar el modelo de reconocimiento (CNN)**, comprender y añadir el **módulo de atención** adaptativa en el modelo.
- 2º Probar un modelo de **reconocimiento de emociones con las imágenes** de la señal para cada emoción etiquetada.
- 3º Mejorar el **modelo GAN** entrenado con otros datos de entrada (segmentos 4D) o aplicando **otros métodos** para reducir la información de forma más correcta.
- 4º **Ampliar** la base de datos.
- 5º Intentar **aplicar** esta metodología a **otros campos** donde pueda ser beneficioso reconocer y generar señales eléctricas (comprobación de redes, electrónica...)



11. Agradecimientos

- **Assembler Institute of Technology:** Por el apoyo aportado durante la ejecución de este proyecto, así como durante todo el período lectivo.
- **Universidad de Shangai Jiao Thon:** Agradecer el acceso a sus bases de datos y la ayuda ofrecida para el entendimiento de los archivos.
- **Compañeros de máster:** por estar hombro con hombro estos 6 meses, ayudarnos y buscar consuelo en los momentos bajos.
- **Lucciano Gabinelli:** Por ser el último en pie de los mentores que empezó esta edición. Por saber escuchar, ayudar y aconsejar en todo lo posible, tanto a nivel personal como intelectual.



¿Preguntas?



**Muchas Gracias
por su Atención**



Trial General





Interpolación




```
# Determine the common length for interpolation
common_length = 50000 # You can adjust this value depending on your needs

interpolated_eeg_data_list = []

for eeg_data in tqdm(eeg_data_list, leave=False):
    num_channels = eeg_data.shape[0]
    original_length = eeg_data.shape[1]
    new_eeg_data = np.zeros((num_channels, common_length))

    for ch_idx in range(num_channels):
        x_original = np.linspace(0, 1, original_length)
        x_new = np.linspace(0, 1, common_length)
        new_eeg_data[ch_idx] = np.interp(x_new, x_original, eeg_data[ch_idx])

    interpolated_eeg_data_list.append(new_eeg_data)
```



Segmentos 4D



```
# Initialize the 4D input with zeros
input_4d_neg = np.zeros((num_segment, height, width, num_maps))


for i, segment in tqdm(enumerate(segment_neg_list), desc="Creating 4D...", leave=False):
    for feature_type_idx, feature_data in enumerate(segment[0]): # Agregar [0] aquí
        current_feature_data = segment[0][feature_type_idx]
        for channel_idx, channel_name in enumerate(electrode_positions):
            for band_idx, band_name in enumerate(freq_bands.keys()):
                x, y = electrode_positions_matrix[channel_name]

# Aplanar los datos
current_feature_data_flat = current_feature_data[band_name].flatten()

# Aplicar Winsorizing
current_feature_data_winsorized = mstats.winsorize(current_feature_data_flat, limits=[0.01, 0.01])

# Remodelar los datos a la forma original
current_feature_data_winsorized = current_feature_data_winsorized.reshape(current_feature_data[band_name].shape)

# Asignar los datos winsorizados a la matriz de entrada
input_4d_neg[i, y, x, band_idx + feature_type_idx * len(freq_bands)] = current_feature_data_winsorized[y, x]
```



CNN



```
model1 = Sequential()

model1.add(Conv2D(32, (3, 3), activation='relu', padding='same', input_shape=input_shape, kernel_regularizer=l2(l2_reg)))
model1.add(BatchNormalization())
model1.add(MaxPooling2D((2, 2)))
model1.add(Dropout(0.25))

model1.add(Conv2D(64, (3, 3), activation='relu', padding='same', kernel_regularizer=l2(l2_reg)))
model1.add(BatchNormalization())
model1.add(MaxPooling2D((2, 2)))
model1.add(Dropout(0.25))

model1.add(Conv2D(128, (3, 3), activation='relu', padding='same', kernel_regularizer=l2(l2_reg)))
model1.add(BatchNormalization())
model1.add(MaxPooling2D((2, 2)))
model1.add(Dropout(0.25))


model1.add(Flatten())

model1.add(Dense(512, activation='relu', kernel_regularizer=l2(l2_reg)))
model1.add(BatchNormalization())
model1.add(Dropout(0.5))

model1.add(Dense(1024, activation='relu', kernel_regularizer=l2(l2_reg)))
model1.add(BatchNormalization())
model1.add(Dropout(0.5))

model1.add(Dense(num_classes, activation='softmax'))

model1.compile(optimizer=Adam(lr=0.001), loss='categorical_crossentropy', metrics=['accuracy'])
```



GAN



```
def build_generator(latent_dim):  
    input_layer = Input(shape=(latent_dim,))  
  
    x = Dense(32)(input_layer)  
    x = LeakyReLU(alpha=0.2)(x)  
    x = BatchNormalization()(x)  
  
    x = Dense(64)(x)  
    x = LeakyReLU(alpha=0.2)(x)  
    x = BatchNormalization()(x)  
  
    x = Dense(128)(x)  
    x = LeakyReLU(alpha=0.2)(x)  
    x = BatchNormalization()(x)  
  
    x = Dense(256)(x)  
    x = LeakyReLU(alpha=0.2)(x)  
    x = BatchNormalization()(x)  
  
    x = Dense(num canales * num_puntos_por_canal, activation='tanh')(x)  
    output_layer = Reshape((num canales, num_puntos_por_canal))(x)  
  
    return Model(input_layer, output_layer)
```

```
# Discriminator  
def build_discriminator():  
    input_layer = Input(shape=(num canales, num_puntos_por_canal))  
    x = Flatten()(input_layer)  
    x = Dense(32)(x)  
    x = LeakyReLU(alpha=0.2)(x)  
    x = Dropout(0.5)(x)  
  
    x = Dense(64)(x)  
    x = LeakyReLU(alpha=0.2)(x)  
    x = Dropout(0.5)(x)  
  
    x = Dense(128)(x)  
    x = LeakyReLU(alpha=0.2)(x)  
    x = Dropout(0.5)(x)  
    output_layer = Dense(1, activation='sigmoid')(x)  
  
    return Model(input_layer, output_layer)
```

```
def build_gan(generator, discriminator):  
    z = Input(shape=(latent_dim,))  
    generated_eeg = generator(z)  
    validity = discriminator(generated_eeg)  
  
    return Model(z, validity)
```